


对话(Chat) API

火山方舟



法律声明

本《火山方舟》的所有内容，包括但不限于文字、商标、架构、图示、图片、页面布局等，其知识产权（著作权、商标权、专利权、商业秘密等）归属于北京火山引擎科技有限公司及其关联公司（火山引擎），非经火山引擎书面同意，任何个人和组织不得复制、使用、修改、转发或以任何违反本《火山方舟》所承载的目的进行传播。

本《火山方舟》陈述内容仅作为产品的通用性介绍和参考性指引，火山引擎保留按“现状”和“当前可用”的形式提供产品和服务的权利。火山引擎不对本《火山方舟》中所载的产品功能、性质、质量、标准等内容进行明示或默示的保证和承诺，最终以您与火山引擎实际签署的协议为准。

如您发现本《火山方舟》有任何错误或歧义，或发现有对本《火山方舟》、产品本身的侵权行为，请与火山引擎取得联系。

联系方式：service@volcengine.com，400-850-0030
(周一至周五 10:00-18:00)

目录

法律声明-----1

目录-----1

1. 对话(Chat) API-----1

1. 对话(Chat) API

POST <https://ark.cn-beijing.volces.com/api/v3/chat/completions> [运行](#)

发送包含文本、图片、视频、音频等模态的消息列表，模型将生成对话中的下一条消息。

Tips：一键展开折叠，快速检索内容

说明

打开页面右上角开关后，**ctrl** + f 可检索页面内所有内容。

展开本文档内所有折叠内容



我的收藏



有用



无用

在线调试

API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

[去调试](#)

快速入口

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)
[开通模型](#) [文本生成](#) [视觉理解](#) [接口文档](#)

请求参数

[跳转](#) [响应参数](#)

请求体

model string 必选

调用的模型 ID（Model ID），[开通模型服务](#)，并[查询 Model ID](#)。

多个应用及精细管理场景，推荐使用 Endpoint ID 调用。详细请参考[获取 Endpoint ID](#)。

messages `object[]` 必选

消息列表，不同模型支持不同类型的消息，如文本、图片、视频、音频等。

消息类型

系统消息 `object`

模型需遵循的指令，包括扮演的角色、背景信息等。

属性

messages.role `string` 必选

发送消息的角色，此处应为 `system` 。

messages.content `string / object[]` 必选

系统消息的内容。

属性

纯文本内容 `string`

纯文本消息内容。

多模态内容 `object[]`

支持文本、图片、视频、音频等模态内容。

各模态内容对象

文本部分 `object`

属性

messages.content.text**** `string` 必选

文本模态部分的内容。

messages.content.type**** `string` 必选

内容模态，此处应为 `text` 。

图片部分 `object`

属性

`messages.content.**type**` `string` 必选

内容模态，此处应为 `image_url`。

`messages.content.**image_url**` `object` 必选

图片模态的内容。

属性

`messages.content.image_url.**url**` `string` 必选

支持格式如下，详细信息请参见[使用说明](#)。

- 图片链接
- 图片的Base64编码

`messages.content.image_url.**detail**` `string`

取值范围：`low`、`high`、`xhigh`。

理解图片的精细度、不同模型默认取值及对应的具体像素区间，参见[控制图片理解的精细度](#)。

`messages.content.image_url.**image_pixel_limit**` `object / null` 默认值 `null`

输入给模型的图片的像素范围，如不在此范围，图片会被等比例缩放至该范围。

注意

图片像素范围需在 `[196, 36,000,000]`，否则会直接报错。

- 生效优先级：高于 `**detail**` 字段，即同时配置 `**detail**` 与 `**image_pixel_limit**` 字段时，生效 `**image_pixel_limit**` 字段配置。
- 默认生效规则：若未设置 `image_pixel_limit`，则使用 `**detail**` 配置的值对应的 `**min_pixels**` / `**max_pixels**` 值。

· `messages.content.image_url.image_pixel_limit.**max_pixels**` `integer`

传入图片最大像素限制，大于此像素则等比例缩小至 `**max_pixels**` 字段取值以下。若未设置，则取值为 `**detail**` 配置的值对应的 `**max_pixels**` 值。

- doubao-seed-1.8 之前的模型取值范围：`(min_pixels, 4014080 ]`
- doubao-seed-1.8、doubao-seed-2.0 模型的取值范围：`(min_pixels, 9031680 ]`。

- `messages.content.image_url.image_pixel_limit.min_pixels` `integer`
传入图片最小像素限制，小于此像素则等比例放大至 `min_pixels` 字段取值以上。若未设置，则取值为 `detail` 配置的值对应的 `min_pixels` 值。
 - doubao-seed-1.8 之前的模型取值范围：[`3136` , `max_pixels`)
 - doubao-seed-1.8、doubao-seed-2.0 模型的取值范围：[`1764` , `max_pixels`)

视频部分 `object`

属性

`messages.content.type` `string` 必选
内容模态，此处应为 `video_url`。

`messages.content.video_url` `object` 必选
视频消息的内容部分。

属性

`messages.content.video_url.url` `string` 必选
支持格式如下，具体使用请参见[视频理解说明](#)。

- 视频链接
- 视频的Base64编码

`messages.content.video_url.fps` `float/ null` 默认值 1
取值范围：[`0.2` , `5`]
抽帧频率，详见[视频理解](#)。

- 取值越高，对视频中画面变化越敏感。
- 取值越低，对视频中画面变化越迟钝，但 token 花费少，速度更快。

音频部分 `object`

多模态消息中，音频模态的部分。音频输入支持 `url`、`data` 两个字段，需二选一传入。具体使用请参见[音频理解](#)。

属性

`messages.content.type` `string` 必选
内容模态，此处应为 `input_audio`。

`messages.content.input_audio` `object` 必选

音频模态的内容。

属性

`messages.content.input_audio.**url` `string`

音频内容的URL。

`messages.content.input_audio.**data` `string`

音频内容的Base64编码。

`messages.content.input_audio.format` `string`

音频格式。当使用`data`时，该参数必填。支持的音频格式 `MIME` 类型如下：
纯音频格式：

- mp3: `audio/mpeg`
- wav: `audio/wav`
- aac: `audio/aac`
- m4a: `audio/mp4`

视频内嵌音频格式：

- mp3: `audio/mpeg`
- wav: `audio/wav`
- aac: `audio/aac`
- m4a: `audio/mp4`
- pcm: `audio/L16`
- ac3: `audio/ac3`
- alac: `audio/mp4`

注意

- 文件大小不超过 25 MB。
- 单次请求音频总时长不超过 120 分钟，仅统计纯音频时长，视频内嵌音频不计入统计。

用户消息 `object`

用户角色发送的消息。不同模型支持的字段类型不同。

属性

`messages.role` `string` 必选

发送消息的角色，此处应为 `user`。

messages.content `string / object[]` 必选

用户信息内容。

内容类型

纯文本内容 `string`

纯文本消息内容。

多模态内容 `object[]`

支持文本、图片、视频、音频等模态内容。

内容类型

文本部分 `object`

多模态消息中，文本模态的部分。

属性

messages.content.text**** `string` 必选

文本模态部分的内容。

messages.content.type**** `string` 必选

内容模态，此处应为 `text`。

图片部分 `object`

属性

messages.content.type**** `string` 必选

消息模态，此处应为 `image_url`。

messages.content.image_url**** `object` 必选

图片模态的内容。

属性

`messages.content.image_url.**url**` `string` 必选

支持格式如下，具体请参见[使用说明](#)。

- 图片链接
- 图片的Base64编码

`messages.content.image_url.**detail**` `string / null`

取值范围：`low`、`high`、`xhigh`。

理解图片的精细度、不同模型默认取值及对应的具体像素区间，参见[控制图片理解的精细度](#)。

`messages.content.image_url.**image_pixel_limit**` `object / null` 默认值 `null`

输入给模型的图片的像素范围，如不在此范围，图片会被等比例缩放至该范围。

注意

图片像素范围需在 [196, 36,000,000]，否则会直接报错。

- 生效优先级：高于 `**detail**` 字段，即同时配置 `**detail**` 与 `**image_pixel_limit**` 字段时，生效 `**image_pixel_limit**` 字段配置。
- 默认生效规则：若未设置 `image_pixel_limit`，则使用 `**detail**` 配置的值对应的 `**min_pixels**` / `**max_pixels**` 值。

- `messages.content.image_url.image_pixel_limit.**max_pixels**` `integer`

传入图片最大像素限制，大于此像素则等比例缩小至 `**max_pixels**` 字段取值以下。若未设置，则取值为 `**detail**` 配置的值对应的 `**max_pixels**` 值。

- doubao-seed-1.8 之前的模型取值范围：(`min_pixels`, 4014080]
- doubao-seed-1.8、doubao-seed-2.0 模型的取值范围：(`min_pixels`, 9031680]。

- `messages.content.image_url.image_pixel_limit.**min_pixels**` `integer`

传入图片最小像素限制，小于此像素则等比例放大至 `**min_pixels**` 字段取值以上。若未设置，则取值为 `**detail**` 配置的值对应的 `**min_pixels**` 值。

- doubao-seed-1.8 之前的模型取值范围：[3136 , `max_pixels`)
- doubao-seed-1.8、doubao-seed-2.0 模型的取值范围：[1764 , `max_pixels`)

视频部分 `object`

属性

`messages.content.**type**` `string` 必选
内容模态，此处应为 `video_url`。

`messages.content.video_url` `object` 必选
视频模态的内容。

属性

`messages.content.video_url.**url**` `string` 必选
支持格式如下，具体使用请参见[视频理解说明](#)。

- 视频链接
- 视频的Base64编码

`messages.content.video_url.fps` `float/ null` 默认值 1
取值范围：`[0.2, 5]`。
抽帧频率，详见[视频理解](#)。

- 取值越高，对视频中画面变化越敏感。
- 取值越低，对视频中画面变化越迟钝，但 token 花费少，速度更快。

音频部分 `object`
多模态消息中，音频模态的部分。音频输入支持`url`、`data`两个字段，需二选一传入。具体使用请参见[音频理解](#)。

属性

`messages.content.**type**` `string` 必选
内容模态，此处应为 `input_audio`。

`messages.content.input_audio` `object` 必选
音频模态的内容。

属性

`messages.content.input_audio.**url**` `string`
音频内容的URL。

`messages.content.input_audio.**data**` `string`
音频内容的Base64编码。

`messages.content.input_audio.format` ****** `string`

音频格式。当使用`data`时，该参数必填。支持的音频格式 `MIME` 类型如下：
纯音频格式：

- `mp3`: `audio/mpeg`
- `wav`: `audio/wav`
- `aac`: `audio/aac`
- `m4a`: `audio/mp4`

视频内嵌音频格式：

- `mp3`: `audio/mpeg`
- `wav`: `audio/wav`
- `aac`: `audio/aac`
- `m4a`: `audio/mp4`
- `pcm`: `audio/L16`
- `ac3`: `audio/ac3`
- `alac`: `audio/mp4`

注意

- 文件大小不超过 25 MB。
- 单次请求音频总时长不超过 120 分钟，仅统计纯音频时长，视频内嵌音频不计入统计。

模型消息 `object`

历史对话中，模型角色返回的消息。用以保持对话一致性，多在[多轮对话](#)及[续写模式](#)使用。

属性

说明

`messages.content` ****** `***` 与 `messages.tool_calls` ****** `***` 至少填写其一。

`messages.role` `string` **必选**

发送消息的角色，此处应为 `assistant`。

`messages.content` `string / array`

模型消息的内容。

`messages.reasoning_content` `string`

模型消息中思维链内容。

仅模型 `doubao-seed-1.8` 、 `deepseek-v3.2` 、 `doubao-seed-2.0` 支持该字段。

`messages.encrypted_content` `string`
经加密及压缩处理后的思考内容原文。自 `doubao-seed-2-0-lite-260428` 版本起，支持该字段输出。

- 注意
- 回传 `encrypted_content` 内容需有效，篡改或无法还原时返回错误： `Invalid signature` 。
 - `encrypted_content` 优先级高于 `reasoning_content` ，回传 `encrypted_content` 时，将忽略 `reasoning_content` 内容。

`messages.tool_calls` `object[]`
模型消息中工具调用部分。

属性

`messages.tool_calls.**function**` `object` 必选
模型返回的需调用的函数信息。

属性

`messages.tool_calls.function.**name**` `string` 必选
需调用的函数的名称。

`messages.tool_calls.function.**arguments**` `string` 必选
需调用的函数的入参，JSON 格式。

说明

模型并不总是生成有效的 JSON，可能会虚构出未定义的参数。建议在调用函数前，验证参数是否有效。

`messages.tool_calls.**id**` `string` 必选
需调用的工具的 ID，由模型生成。

`messages.tool_calls.**type**` `string` 必选
消息类型，当前仅支持 `function` 。

工具消息 `object`

历史对话中，调用工具返回的消息。工具调用场景中使用。

属性

`messages.role` `string` 必选

发送消息的角色，此处应为 `tool`。

`messages.content` `string / array` 必选

工具返回的消息。

`messages.**tool_call_id**` `string` 必选

模型生成的需调用工具请求时，生成的ID。在程序调用工具的返回需要附上同一 ID，来关联工具结构与模型请求。避免多工具调用时混淆信息。

`thinking` `object` 默认值 `{"type":"enabled"}`

控制模型是否开启深度思考模式。

不同模型是否支持以及默认取值不同，详情请查询[文档](#)。

属性

`thinking.**type**` `string` 必选

取值范围：`enabled`，`disabled`，`auto`。

- `enabled`：开启思考模式，模型强制先思考再回答。
 - `disabled`：关闭思考模式，模型直接回答问题，不进行思考。
 - `auto`：自动思考模式，模型根据问题自主判断是否需要思考，简单题目直接回答。
-

`stream` `boolean / null` 默认值 `false`

响应内容是否流式返回：

- `false`：模型生成完所有内容后一次性返回结果。
 - `true`：按 SSE 协议逐块返回模型生成内容，并以一条 `data:[DONE]` 消息结束。当 `stream` 为 `true` 时，可设置 `stream_options` 字段以获取 token 用量统计信息。
-

stream_options object / null 默认值 null

流式响应的选项。当 **stream** 为 **true** 时，可设置 **stream_options** 字段。

属性

stream_options.include_usage boolean / null 默认值 false

模型流式输出时，是否在输出结束前输出本次请求的 token 用量信息。

- **true**：在 **data:[DONE]** 消息之前会返回一个额外的 chunk。此 chunk 中，**usage** 字段中输出整个请求的 token 用量，**choices** 字段为空数组。
- **false**：输出结束前，没有一个 chunk 来返回 token 用量信息。

stream_options.chunk_include_usage boolean / null 默认值 false

模型流式输出时，输出的每个 chunk 中是否输出本次请求到此 chunk 输出时刻的累计 token 用量信息。

- **true**：在返回的 **usage** 字段中，输出本次请求到此 chunk 输出时刻的累计 token 用量。
- **false**：不在每个 chunk 都返回 token 用量信息。

max_tokens integer / null 默认值 4096

取值范围：各个模型不同，详细见[模型列表](#)。

模型回答最大长度（单位 token）。

说明

- 模型回答不包含思维链内容，模型回答 = 模型输出 - 模型思维链（如有）
- 输出 token 的总长度还受模型的上下文长度限制。

max_completion_tokens integer / null

支持该字段的模型及使用说明见 [文档](#)。

取值范围：[1,65,536]。

控制模型输出的最大长度（包括模型回答和模型思维链内容长度，单位 token）。

配置了该参数后，可以让模型输出超长内容，**max_tokens** 默认值失效，模型按需输出内容（回答和思维链），直到达到 **max_completion_tokens** 值。

不可与 **max_tokens** 字段同时设置。

service_tier string / null 默认值 auto

控制使用的在线推理模式。取值范围： fast 、 auto 、 default 。

- **fast** ：本次请求优先使用 [在线推理（低延迟）](#) 模式。
 - 推理接入点（ **model** 字段指定 ）有低延迟限流配额，本次请求将会优先使用低延迟限流配额，获得更高的服务等级（延迟、可用性等）。
 - 推理接入点（ **model** 字段指定 ）无低延迟限流配额，或者限流配额已满，降级至 [在线推理（常规）](#) 模式，维持常规的服务等级。
- **auto** ：本次请求优先使用 [在线推理（TPM保障包）](#) 模式。
 - 推理接入点（ **model** 字段指定 ）*** 有 TPM 保障包额度，本次请求将会优先使用 TPM 保障包额度，获得最高的服务等级（延迟、可用性等）。
 - 推理接入点（ **model** 字段指定 ）*** 无 TPM 保障包额度或用超额度，降级至 [在线推理（常规）](#) 模式，维持常规的服务等级。
- **default** ：本次请求只使用 [在线推理（常规）](#) 模式。维持常规的服务等级，即使调用的推理接入点有TPM保障包额度 / 低延迟限流额度。

stop string / string[] / null 默认值 null

模型遇到 stop 字段所指定的字符串时将停止继续生成，这个词语本身不会输出。最多支持 4 个字符串。

[深度思考能力模型](#) 不支持该字段。

["你好", "天气"]

reasoning_effort string / null 默认值 medium

支持该字段的模型、与 **thinking.type** 字段关系见[文档](#)。

限制思考的工作量。减少思考深度可提升速度，思考花费的 token 更少。

取值范围： minimal ， low ， medium ， high ， max （仅部分模型支持）。

- **minimal** ：关闭思考，直接回答。
- **low** ：轻量思考，侧重快速响应。
- **medium** ：均衡模式，兼顾速度与深度。
- **high** ：深度分析，处理复杂问题。
- **max** ：最高程度思考，适配高难度推理任务。该参数仅对指定模型生效，非适配模型传入将不生效。支持模型列表：
 - `deepseek-v4-pro-260425`
 - `deepseek-v4-flash-260425`

response_format object 默认值 {"type": "text"} beta阶段

指定模型回答格式。

回答格式说明

文本格式 `object`

模型默认回复文本格式内容。

属性

`response_format.type` `string` 必选

此处应为 `text`。

JSON Object 格式 `object`

模型回复内容以JSON对象结构来组织。

支持该字段的模型请参见[文档](#)。

该能力尚在 beta 阶段，请谨慎在生产环境使用。

属性

`response_format.**type` `string` 必选

此处应为 `json_object`。

JSON Schema 格式 `object`

模型回复内容以JSON对象结构来组织，遵循 `**schema` 字段定义的JSON结构。

支持该字段的模型请参见[文档](#)。

该能力尚在 beta 阶段，请谨慎在生产环境使用。

属性

`response_format.**type` `string` 必选

此处应为 `json_schema`。

`response_format.json_schema` `object` 必选

JSON结构体的定义。

属性

`response_format.json_schema.name` `string` 必选

用户自定义的JSON结构的名称。

response_format.json_schema.description string / null

回复用途描述，模型将根据此描述决定如何以该格式回复。

response_format.json_schema.schema object 必选

回复格式的 JSON 格式定义，以 JSON Schema 对象的形式描述。

response_format.json_schema.strict boolean / null 默认值 false

是否在生成输出时，启用严格遵循模式。

- **true**：模型将始终严格遵循**schema**字段中定义的格式。
- **false**：模型会尽可能遵循**schema**字段中定义的结构。

frequency_penalty float / null 默认值 0

取值范围为 [-2.0 , 2.0]。

注意

doubao-seed-1.8 、 doubao-seed-2.0 系列模型不支持该字段。

频率惩罚系数。如值为正，根据新 token 在文本中的出现频率对其进行惩罚，从而降低模型逐字重复的可能性。

presence_penalty float / null 默认值 0

取值范围为 [-2.0 , 2.0]。

注意

doubao-seed-1.8 、 doubao-seed-2.0 系列模型不支持该字段。

存在惩罚系数。如果值为正，会根据新 token 到目前为止是否出现在文本中对其进行惩罚，从而增加模型谈论新主题的可能性。

temperature float / null 默认值 1

取值范围为 [0 , 2]。

注意

当调用下列模型，字段取值固定为 **1**，手动指定的参数值将被忽略。

- doubao-seed-2-0-pro-260215

- `doubao-seed-2-0-lite-260215`

采样温度。控制了生成文本时对每个候选词的概率分布进行平滑的程度。当取值为 0 时模型仅考虑对数概率最大的一个 token。

较高的值（如 0.8）会使输出更加随机，而较低的值（如 0.2）会使输出更加集中确定。

通常建议仅调整 temperature 或 top_p 其中之一，不建议两者都修改。

top_p float / null 默认值 0.7

取值范围为 [0 , 1]。

注意

当调用下列模型，字段取值固定为 `0.95`，手动指定的参数值将被忽略。

- `doubao-seed-2-0-pro-260215`
- `doubao-seed-2-0-lite-260215`
- `doubao-seed-1-8-251228`

核采样概率阈值。模型会考虑概率质量在 top_p 内的 token 结果。当取值为 0 时模型仅考虑对数概率最大的一个 token。

0.1 意味着只考虑概率质量最高的前 10% 的 token，取值越大生成的随机性越高，取值越低生成的确定性越高。通常建议仅调整 temperature 或 top_p 其中之一，不建议两者都修改。

logprobs boolean / null 默认值 false

带深度思考能力模型不支持该字段，深度思考能力模型参见[文档](#)。

是否返回输出 tokens 的对数概率。

- `false`：不返回对数概率信息。
- `true`：返回消息内容中每个输出 token 的对数概率。

top_logprobs integer / null 默认值 0

带深度思考能力模型不支持该字段，深度思考能力模型参见[文档](#)。

取值范围为 [0 , 20]。

指定每个输出 token 位置最有可能返回的 token 数量，每个 token 都有关联的对数概率。仅当 logprobs 为 `true` 时可以设置 top_logprobs 参数。

logit_bias map / null 默认值 null

带深度思考能力模型不支持该字段，深度思考能力模型参见[文档](#)。

调整指定 token 在模型输出内容中出现的概率，使模型生成的内容更加符合特定的偏好。**logit_bias** 字段接受一个 map 值，其中每个键为词表中的 token ID（使用 tokenization 接口获取），每个值为该 token 的偏差值，取值范围为 [-100, 100]。

-1 会减少选择的可能性，1 会增加选择的可能性；-100 会完全禁止选择该 token，100 会导致仅可选择该 token。该参数的实际效果可能因模型而异。

```
{"<Token_ID>": -100}
```

tools `object[] / null` 默认值 `null`

待调用工具的列表，模型返回信息中可包含。当您需要让模型返回待调用工具时，需要配置该结构体。支持该字段的模型请参见 [文档](#)。

属性

tools.type**** `string` 必选
工具类型，此处应为 `function`。

tools.function**** `object` 必选
模型返回中可包含待调用的工具。

属性

tools.function.name**** `string` 必选
调用的函数的名称。

tools.function.description**** `string`
调用的函数的描述，大模型会使用它来判断是否调用这个工具。

tools.function.parameters**** `object`
函数请求参数，以 JSON Schema 格式描述。具体格式请参考 [JSON Schema](#) 文档，格式如下：

```
{
  "type": "object",
  "properties": {
    "参数名": {
      "type": "string | number | boolean | object | array",
      "description": "参数说明"
    }
  }
},
```

```
JSON {
  "required": ["必填参数"]
}
```

其中，

- 所有字段名大小写敏感。
- **parameters** 须是合规的 JSON Schema 对象。
- 建议用英文字段名，中文置于 **description** 字段中。

parallel_tool_calls `boolean` 默认值 `true`

本次请求，模型返回是否允许包含多个待调用的工具。

- `true`：允许返回多个待调用的工具。
- `false`：允许返回的待调用的工具小于等于1，本取值在 `doubao-seed-1.6` 及之后系列模型生效。

tool_choice `string / object`

仅 `doubao-seed-1.6` 及之后系列模型支持此字段。

本次请求，模型返回信息中是否有待调用的工具。

当没有指定工具时，`none` 是默认值。如果存在工具，则 `auto` 是默认值。

可选类型

选择模式 `string`

控制模型返回是否包含待调用的工具。

- `none`：模型返回信息中不可含有待调用的工具。
- `required`：模型返回信息中必须含待调用的工具。选择此项时请确认存在适合的工具，以减少模型产生幻觉的情况。
- `auto`：模型自行判断返回信息是否有待调用的工具。

工具调用 `object`

指定待调用工具的范围。模型返回信息中，只允许包含以下模型信息。选择此项时请确认该工具适合用户需求，以减少模型产生幻觉的情况。

属性

tool_choice.type `string` `%%require%%`
调用的类型，此处应为 `function`。

tool_choice.function `object` `%%require%%`

调用工具的信息。

属性

tool_choice.function **.name ** `string` `%%require%%`

待调用工具的名称。

响应参数

跳转 [请求参数](#)

非流式调用返回

跳转 [流式调用返回](#)

id `string`

本次请求的唯一标识。

model `string`

本次请求实际使用的模型名称和版本。

service_tier `string`

本次请求的请求使用的模式。

- `scale` : 本次请求使用 [在线推理（TPM保障包）](#) 模式。
- `default` : 本次请求使用 [在线推理（常规）](#) 模式。
- `fast` : 本次请求使用 [在线推理（低延迟）](#) 模式。

created `integer`

本次请求创建时间的 Unix 时间戳（秒）。

object `string`

固定为 `chat.completion` 。

choices `object[]`

本次请求的模型输出内容。

属性

`choices.**index** integer`

当前元素在 **choices** 列表的索引。

`choices.**finish_reason** string`

模型停止生成 token 的原因。取值范围：

- `stop` : 模型输出自然结束，或因命中请求参数 `stop` 中指定的字段而被截断。
 - `length` : 模型输出因达到模型输出限制而被截断，有以下原因：
 - 触发 `max_tokens` 限制（回答内容的长度限制）。
 - 触发 `max_completion_tokens` 限制（思维链内容+回答内容的长度限制）。
 - 触发 `context_window` 限制（输入内容+思维链内容+回答内容的长度限制）。
 - `content_filter` : 模型输出被内容审核拦截。
 - `tool_calls` : 模型调用了工具。
-

`choices.**message** object`

模型输出的内容。

属性

`choices.message.**role** string`

内容输出的角色，此处固定为 `assistant` 。

`choices.message.**content** string`

模型生成的消息内容。

`choices.message.**reasoning_content** string / null`

模型处理问题的思维链内容。

仅深度推理模型支持返回此字段，深度推理模型请参见[支持模型](#) .

`choices.message.**tool_calls** object[] / null`

模型生成的工具调用。

属性

`choices.message.tool_calls.id** string`

调用的工具的 ID。

`choices.message.tool_calls.**type` `string`

工具类型，当前仅支持 `function`。

`choices.message.tool_calls.**function` `object`

模型调用的函数。

属性

`choices.message.tool_calls.function.**name` `string`

模型调用的函数的名称。

`choices.message.tool_calls.function.**arguments` `string`

模型生成的用于调用函数的参数，JSON 格式。

模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效。

`choices.**logprobs` `object / null`

当前内容的对数概率信息。

属性

`choices.logprobs.**content` `object[] / null`

message列表中每个 content 元素中的 token 对数概率信息。

属性

`choices.logprobs.content.**token` `string`

当前 token。

`choices.logprobs.content.**bytes` `integer[] / null`

当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

`choices.logprobs.content.**logprob` `float`

当前 token 的对数概率。

`choices.logprobs.content.**top_logprobs` `object[]`

在当前 token 位置最有可能的标记及其对数概率的列表。在一些情况下，返回的数量可能比请求参数 `top_logprobs` 指定的数量要少。

属性

`choices.logprobs.content.top_logprobs.**token` `string`

当前 token。

`choices.logprobs.content.top_logprobs.**bytes` `integer[] / null`

当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

`choices.logprobs.content.top_logprobs.**logprob` `float`

当前 token 的对数概率。

`choices.**moderation_hit_type` `string / null`

模型输出文字含有敏感信息时，会返回模型输出文字命中的风险分类标签。

返回值及含义：

- `severe_violation`：模型输出文字涉及严重违规。
- `violence`：模型输出文字涉及激进行为。

注意：当前只有[视觉理解模型](#)支持返回该字段，且只有在方舟控制台[接入点配置页面](#)或者 [CreateEndpoint](#) 接口中，将内容护栏方案（ModerationStrategy）设置为基础方案（Basic）时，才会返回风险分类标签。

`usage` `object`

本次请求的 token 用量。

属性

`usage.**total_tokens` `integer`

本次请求消耗的总 token 数量（输入 + 输出）。

`usage.**prompt_tokens` `integer`

输入给模型处理的内容 token 数量。

`usage.**prompt_tokens_details` `object`

输入给模型处理的内容 token 数量的细节。

属性

`usage.prompt_tokens_details.**cached_tokens` `integer`
缓存命中的输入内容（含文本、音频等所有类型）所消耗的 token 总数。

`usage.prompt_tokens_details.**audio_tokens` `integer`
音频输入内容所消耗的 token 数量。

`usage.prompt_tokens_details.audio_cached_tokens` `integer`
缓存命中的音频输入内容所消耗的 token 数量。

`usage.**completion_tokens` `integer`
模型输出内容花费的 token。

`usage.**completion_tokens_details` `object`
模型输出内容花费的 token 的细节。

属性

`usage.completion_tokens_details.**reasoning_tokens` `integer`
输出思维链内容花费的 token 数。
支持输出思维链的模型请参见[文档](#) .

流式调用返回

跳转 [非流式调用返回](#)

`id` `string`
本次请求的唯一标识。

`model` `string`
本次请求实际使用的模型名称和版本。

service_tier `string`

本次请求是否使用了TPM保障包。

- `scale` : 本次请求使用 [在线推理（TPM保障包）](#) 模式。
- `default` : 本次请求使用 [在线推理（常规）](#) 模式。
- `fast` : 本次请求使用 [在线推理（低延迟）](#) 模式。

created `integer`

本次请求创建时间的 Unix 时间戳（秒）。

object `string`

固定为 `chat.completion.chunk` 。

choices `object[]`

本次请求的模型输出内容。

属性

choices.index** `integer`

当前元素在 **choices** 列表的索引。

choices.finish_reason** `string`

模型停止生成 token 的原因。取值范围：

- `stop` : 模型输出自然结束，或因命中请求参数 `stop` 中指定的字段而被截断。
- `length` : 模型输出因达到模型输出限制而被截断，有以下原因：
 - 触发 `max_tokens` 限制（回答内容的长度限制）。
 - 触发 `max_completion_tokens` 限制（思维链内容+回答内容的长度限制）。
 - 触发 `context_window` 限制（输入内容+思维链内容+回答内容的长度限制）。
- `content_filter` : 模型输出被内容审核拦截。
- `tool_calls` : 模型调用了工具。

choices.delta** `object`

模型输出的增量内容。

属性

`choices.delta.**role**` `string`
内容输出的角色，此处固定为 `assistant`。

`choices.delta.**content**` `string`
模型生成的消息内容。

`choices.delta.**reasoning_content**` `string / null`
思考内容原文。自 `doubao-seed-2-0-lite-260428` 版本起，返回思考内容摘要。
仅深度推理模型支持返回此字段，深度推理模型请参见[支持模型](#)。

注意

针对长文本生成、深度推理等耗时场景，建议适当调大首 Token 超时时间（TTFT）与逐 Token 生成超时时间（TPOT），避免请求因超时而中断。

`choices.delta.**encrypted_content**` `string`
经加密及压缩处理后的思考内容原文。自 `doubao-seed-2-0-lite-260428` 版本起，支持该字段输出。

说明

流式输出场景下，将在思考内容输出完成后、正式应答内容输出前，输出包含完整 `encrypted_content` 的数据。其中 `content` 与 `reasoning_content` 字段均为空。

`choices.delta.**tool_calls**` `object[] / null`
模型生成的工具调用。

属性

`choices.delta.tool_calls.**id**` `string`
调用的工具的 ID。

`choices.delta.tool_calls.**type**` `string`
工具类型，当前仅支持 `function`。

`choices.delta.tool_calls.**function**` `object`
模型调用的函数。

属性

`choices.delta.tool_calls.function.**name` `string`

模型调用的函数的名称。

`choices.delta.tool_calls.function.**arguments` `string`

模型生成的用于调用函数的参数，JSON 格式。

模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效。

`choices.**logprobs` `object / null`

当前内容的对数概率信息。

属性

`choices.logprobs.**content` `object[] / null`

message列表中每个 content 元素中的 token 对数概率信息。

属性

`choices.logprobs.content.**token` `string`

当前 token。

`choices.logprobs.content.**bytes` `integer[] / null`

当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

`choices.logprobs.content.**logprob` `float`

当前 token 的对数概率。

`choices.logprobs.content.**top_logprobs` `object[]`

在当前 token 位置最有可能的标记及其对数概率的列表。在一些情况下，返回的数量可能比请求参数 `top_logprobs` 指定的数量要少。

属性

choices.logprobs.content.top_logprobs.**token** string

当前 token。

choices.logprobs.content.top_logprobs.**bytes** integer[] / null

当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

choices.logprobs.content.top_logprobs.**logprob** float

当前 token 的对数概率。

choices.**moderation_hit_type** string/ null

模型输出文字含有敏感信息时，会返回模型输出文字命中的风险分类标签。

返回值及含义：

- `severe_violation`：模型输出文字涉及严重违规。
- `violence`：模型输出文字涉及激进行为。

注意：当前只有[视觉理解模型](#)支持返回该字段，且只有在方舟控制台[接入点配置页面](#)或者 [CreateEndpoint](#) 接口中，将内容护栏方案（ModerationStrategy）设置为基础方案（Basic）时，才会返回风险分类标签。

usage object

本次请求的 token 用量。

流式调用时，默认不统计 token 用量信息，返回值为 `null`。

如需统计，需设置 `stream_options.include_usage` 为 `true`。

属性

usage.**total_tokens** integer

本次请求消耗的总 token 数量（输入 + 输出）。

usage.**prompt_tokens** integer

输入给模型处理的内容 token 数量。

usage.**prompt_tokens_details** object

输入给模型处理的内容 token 数量的细节。

属性

`usage.prompt_tokens_details.**cached_tokens **` `integer`

缓存输入内容的 token 用量，此处应为 `0`。

`usage.prompt_tokens_details.**audio_tokens **` `integer`

音频输入内容所消耗的 token 数量。

`usage.prompt_tokens_details.audio_cached_tokens ** **` `integer`

缓存音频输入内容的 token 用量。

`usage.**completion_tokens **` `integer`

模型输出内容花费的 token。

`usage.**completion_tokens_details **` `object`

模型输出内容花费的 token 的细节。

属性

`usage.completion_tokens_details.**reasoning_tokens **` `integer`

输出思维链内容花费的 token 数。

支持输出思维链的模型请参见[文档](#) [🔗](#)。